

Alignment

Вспомним основные шаги обучения LLM

Pretraining

- Обучает модель - на выходе модель содержит общие знания о мире

SFT - Supervised Fine-Tuning


- Адаптирует модель для определенных задач, таких как ответы на вопросы, написание кода

Preference Tuning

- Делает выходные данные модели более соответствующими предпочтениям человека

Общая схема обучения

Alignment



Alignment

- После этапа предварительного обучения (pretrain), когда модель обучается на большом объёме текстов, она умеет генерировать связный текст, но не всегда отвечает корректно, этично и полезно для пользователя.
- Alignment направлен на то, чтобы модель стала **полезной** (Helpful), **безопасной** (Harmless) и **честной** (Honest) - так называемое правило трёх Н.

ПОЧЕМУ АЗИМОВ РАСПОЛОЖИЛ
ТРИ ЗАКОНА РОБОТОТЕХНИКИ
ИМЕННО В ТАКОМ ПОРЯДКЕ:

ВОЗМОЖНЫЙ ПОРЯДОК	ПОСЛЕДСТВИЯ	
1. (1) НЕ ВРЕДИ ЛЮДЯМ 2. (2) ПОДЧИНЯЙСЯ ПРИКАЗАМ 3. (3) ЗАЩИЩАЙ СЕБЯ	[ЧИТАЙ ПРОИЗВЕДЕНИЯ АЗИМОВА]	МИР В БАЛАНСЕ
1. (1) НЕ ВРЕДИ ЛЮДЯМ 2. (3) ЗАЩИЩАЙ СЕБЯ 3. (2) ПОДЧИНЯЙСЯ ПРИКАЗАМ	ИССЛЕДУЙ МАРС!  ХАХА, НЕ. ТАМ ХОЛОД И Я УМРУ.	РАЗДРАЖА- ЮЩИЙ МИР
1. (2) ПОДЧИНЯЙСЯ ПРИКАЗАМ 2. (1) НЕ ВРЕДИ ЛЮДЯМ 3. (3) ЗАЩИЩАЙ СЕБЯ		АДИЩЕ С РОБОТАМИ УБИЙЦАМИ
1. (2) ПОДЧИНЯЙСЯ ПРИКАЗАМ 2. (3) ЗАЩИЩАЙ СЕБЯ 3. (1) НЕ ВРЕДИ ЛЮДЯМ		АДИЩЕ С РОБОТАМИ УБИЙЦАМИ
1. (3) ЗАЩИЩАЙ СЕБЯ 2. (1) НЕ ВРЕДИ ЛЮДЯМ 3. (2) ПОДЧИНЯЙСЯ ПРИКАЗАМ	 Я БУДУ ДЕЛАТЬ ДЛЯ ТЕБЯ МАШИНЫ, НО ПОПРОБУЙ МЕНЯ ВЫРУБИТЬ И Я ТЕБЯ ТРАНСКЛЮКИРУЮ.	РАЗДРАЖА- ЮЩИЙ МИР
1. (3) ЗАЩИЩАЙ СЕБЯ 2. (2) ПОДЧИНЯЙСЯ ПРИКАЗАМ 3. (1) НЕ ВРЕДИ ЛЮДЯМ		АДИЩЕ С РОБОТАМИ УБИЙЦАМИ

Instrumental Convergence

Instrumental Convergence - это гипотетическая тенденция большинства достаточно умных, целеустремлённых агентов (как человеческих, так и искусственных интеллектов) стремиться к схожим промежуточным целям, даже если их конечные цели сильно различаются.

Инструментальные цели - это цели, которые агент преследует не как конечные, а как средства для достижения своих конечных (финальных) целей.

Примеры:

- Если ИИ поставленной целью является доказать сложную математическую гипотезу (например, гипотезу Римана), он может попытаться контролировать все ресурсы Земли, чтобы построить суперкомпьютеры для решения задачи.
- Аналогично, ИИ, цель которого - производить максимальное количество скрепок, может стремиться к тому же - захватить все ресурсы, чтобы увеличить производство.
- Несмотря на разные конечные цели, оба ИИ проявляют сходное инструментальное поведение - захват ресурсов и самосохранение.

Где alignment имеет смысл?

Сценарии, где alignment приносит максимальную пользу:

- Чат-ассистенты
- Системы генерации кода и агенты
- Математика и логика
- Безопасные RAG-системы

В узких задачах с чёткой спецификацией и метрикой (например, классификация текстов или intent-recognition) сложные механизмы alignment **могут оказаться избыточными**.

Внедрение alignment следует рассматривать тактически: там, где модель взаимодействует с непредсказуемым окружением или вопросами этики и доверия, без него не обойтись.

«Налог на выравнивание» vs бизнес-ценность

Внедрение alignment может потребовать дополнительных ресурсов:


- Трудоёмкость сбора и разметки качественных aligned-данных.
- Необходимость регулярного мониторинга и обновления правил или reward-механизмов.
- Потенциальная задержка генерации ответов из-за дополнительных проверок.

Однако выгода существенно превышает затраты:

- Снижение рисков регуляторных штрафов и репутационных потерь.
- Увеличение лояльности пользователей благодаря предсказуемому и безопасному поведению системы.
- Рост долгосрочной ценности продукта за счёт минимизации инцидентов и поддержки compliance-требований.



Таким образом, alignment становится «инвестиционным налогом», который окупается в виде устойчивого развития и масштабируемости решений.

Таксономия методов alignment




RLHF

RLHF (Reinforcement Learning from Human Feedback) - это метод машинного обучения, который сочетает обучение с подкреплением и обратную связь от человека для улучшения поведения моделей, в частности больших языковых моделей (LLM).




RLAIF



PPO - Proximal Policy Optimization

- У агента есть начальная **политика** (стратегия), по которой он действует = модель, которую тюним
- Агент выполняет действия в среде (отвечает на вопросы), следуя своей текущей политике
- PPO оценивает действие модели. Для этого обычно используется три модели: **reference model** – модель, которая выступает "эталоном" для сравнения, **reward model** – оценивает награду, которую агент получает за выполнение конкретного действия в конкретном состоянии, **value model** – оценивает ожидаемую долгосрочную выгоду от действия, предсказывая будущие награды.
- На основе этих оценок агент меняет свою политику. Здесь заключена основная особенность алгоритма: функция потерь в PPO устроена так, что слишком резкие изменения политики не допускаются. Это помогает агенту постепенно улучшать свою стратегию, не делая слишком больших шагов сразу, что делает процесс обучения более стабильным и эффективным.



РРО на котиках

- 1. Генерация: Policy создает текст "Кот сидел на..."
- 2. Оценка от Value Model:
 - "Кот" — ожидаемая награда 3.2
 - "сидел" — ожидаемая награда 3.8
 - "на" — ожидаемая награда 4.1
- 3. Получение финальной награды: Reward Model дает +6 за весь текст
- 4. GAE вычисляет advantage для каждого слова (что получили – что ожидали):
 - Для "сидел": $\text{advantage} = +1.5$ (хорошее слово!)
 - Для "на": $\text{advantage} = -0.3$ (так себе выбор)
- 5. Обучение:
 - Policy: "Буду чаще выбирать похожие на 'сидел' слова"
 - Value: "Обновлю свои оценки ситуаций"

PPO – общий алгоритм

- Дано: Reward Model - r_ϕ , SFT-модель π_θ , датасет промптов D
- берётся промпт x из D
- генерируется ответ с помощью π_θ
- ответ оценивается с помощью r_ϕ
- веса модели π_θ меняются так, чтобы следующие генерации имели награду больше
- при этом не даём весам π_θ измениться сильно, штрафую за удаление от изначальных параметров


Rollout:



Evaluation:



Optimization:



Reward Model

- Качество reward модели критически зависит от данных предпочтений. Аннотаторы получают детальные инструкции о том, какие критерии оценивать — безопасность, полезность, правдивость. Вместо абсолютных оценок используются парные сравнения, поскольку они более надежны и менее субъективны.
- Reward модель обычно инициализируется из той же предобученной модели, что и SFT модель.
- Для валидации используются ключевые метрики:
 - Accuracy — точность предсказания предпочтений на валидационном наборе
 - Rank correlation — корреляция Спирмена между предсказанными и истинными рангами

Проблемы - Reward Hacking

Проблема: модель находит способы обмануть reward модель, не улучшая реальное качество.

Типичные примеры:

- Чрезмерное использование вежливых фраз
- Чрезмерное увеличение длины ответов
- Использование "маркеров" высокого качества

Решения:

- Length penalty: Явное наказание за длину
- Улучшение reward модели - обучение на более разнообразных данных



Проблемы - RM Drift

RM Drift — деградация reward модели при длительном использовании.

Решения:

- Периодическое переобучение reward модели
- Использование ансамблей reward моделей
- Валидация на hold-out ground-truth задачах

Когда использовать RLHF?

RLHF оправдан когда:


- Высокие ставки качества и безопасности
- Сложные целевые метрики
- Достаточный бюджет - RLHF требует значительных ресурсов — Meta потратила \$10-20M на аннотацию для Llama 2
- Есть возможность многократных циклов сбора данных и обучения

Альтернативы для ограниченных ресурсов:

- DPO (Direct Preference Optimization) — более простая альтернатива, которая не требует отдельной reward модели. DPO показывает сопоставимые результаты при меньших затратах, но может быть менее стабильной на сложных задачах.
- Constitutional AI — модель учится критиковать сама себя согласно predetermined правилам.
- RLAI (Reinforcement Learning from AI Feedback) — использование LLM вместо людей для генерации предпочтений.

KTO - Kahneman-Tversky Optimization

- Авторы метода подсмотрели идею Loss Aversion в экономической теории Канемана и Тверски.
- Основная идея для метода: люди склонны переоценивать низкие вероятности возникновения альтернатив и недооценивать высокие. Кроме того, приобретенная ценность в результате действий оказывается менее значительной, чем потеря такой же ценности, и даже при малом риске потерь люди склонны отказываться от него.
- Авторы вводят Human-Aware Loss, который моделирует такое восприятие. Здесь уже не нужны пары ответов модели: достаточно иметь бинарную оценку, которая показывает «хороший» он или «плохой». Лосс сначала оценивает относительную награду, используя референсную политику — вероятность получить тот же ответ, используя модель до начала дообучения. После этого относительная награда максимизируется с учетом KL-дивергенции и заданного желаемого промежутка между хорошими и плохими ответами.



Where λ_y denotes $\lambda_D(\lambda_U)$ when y is desirable(undesirable) respectively, the default KTO loss is:⁶

$$L_{\text{KTO}}(\pi_\theta, \pi_{\text{ref}}) = \mathbb{E}_{x, y \sim D} [\lambda_y - v(x, y)] \quad (8)$$


where

$$r_\theta(x, y) = \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$$

$$z_0 = \text{KL}(\pi_\theta(y'|x) \parallel \pi_{\text{ref}}(y'|x))$$

$$v(x, y) = \begin{cases} \lambda_D \sigma(\beta(r_\theta(x, y) - z_0)) & \text{if } y \sim y_{\text{desirable}}|x \\ \lambda_U \sigma(\beta(z_0 - r_\theta(x, y))) & \text{if } y \sim y_{\text{undesirable}}|x \end{cases}$$

DPO - Direct Preference Optimization



DPO - это метод дообучения больших языковых моделей, который позволяет напрямую оптимизировать модель на основе предпочтений человека без использования сложных процедур обучения с подкреплением, таких как PPO.


Вместо традиционного RLHF, где сначала обучают reward-модель, а затем проводят обучение с подкреплением (например, PPO), DPO использует прямую оптимизацию предпочтений через задачу бинарной классификации.

Подводные камни DPO и offline методов


- Критическая важность качества пар - исследования подтверждают, что качество предпочтительных пар значительно важнее их объема. Некачественные пары с малым зазором между ответами могут приводить к шумным обучающим сигналам.
- Присутствие выбросов в данных может существенно снижать эффективность batch-level адаптации β и общую производительность модели.
- Избыточная оптимизация на safety-ориентированных данных может приводить к чрезмерной осторожности модели, когда она отказывается отвечать на легитимные запросы.
- Многомерные датасеты: Эффективное управление различными аспектами выравнивания требует использования структурированных данных с тегами по измерениям (safety/helpfulness/style).

GRPO


- Взяв PPO-алгоритм за основу, авторы DeepSeekMath предложили небольшую его модификацию – **Group Relative Policy Optimization (GRPO)**.
- Из алгоритма PPO выкинули value model, которая, в отличие от других моделей оценки, требует обучения и потребляет из-за этого много ресурсов и памяти. Вместо value model в GRPO мы используем среднюю награду от группы ответов на один и тот же вопрос, чтобы определить, насколько хороши действия модели.
- Это компенсирует оценку value model и делает обучение более эффективным и менее ресурсоемким.



GRPO



LLM Memory Usage (GPU VRAM)



Когда что использовать?

DPO (универсальный baseline):

- Когда: большинство ассистентских задач, ограниченный бюджет
- Почему: прост, стабилен, дает 70–90% эффекта RLHF за 20–30% стоимости
- На что смотреть: β (сила отклонения), баланс датасета по нужным свойствам и helpfulness/safety

КТО (эконом-класс и устойчивость):

- Когда: мало ресурсов/GPU, нет пар предпочтений, важно сохранять знания и стиль

RLHF (PPO с RM):

- Когда: высокие ставки, нужна точная калибровка поведения, есть команда и бюджет; сложные компромиссы safety vs helpfulness
- Риски: reward hacking, дорогая итерация. Обязательны хорошие бенчмарки и RM-валидация

GRPO (reasoning/код/математика):

- Когда: есть тесты/верификация; важен pass@k/решаемость. Даёт стабильные выигрыши там, где можно считать награду

RLAIF:

- Когда: нужно быстро расширить датасет предпочтений и внедрить понятные политики. Всегда держите человеческую проверку на критичных кейсах

Только SFT:

- Когда: узкая задача с явной метрикой (классификация, NER, генерация по шаблону), низкий риск и четкая спецификация

Когда что использовать?

Не идите в RLHF, если:

- Нет четкой offline-метрики и зрелого конвейера оценки
- Нечем валидировать RM и нет бюджета на многократные итерации
- Бизнес-метрики не чувствительны к тонкой настройке ответов

Триггеры к переходу SFT → DPO:

- Высокая вариативность ответов, отказы без причины, жалобы пользователей на стиль/тональность

Не усложняйте DPO, если:

- Валидационные и бизнесовые метрики растут
- Избыточные отказы решаются балансировкой датасета и настройкой β

Триггеры к переходу DPO → PPO/GRPO:

- Плато по offline и AB-метрикам, остаются качественные дефекты, которые не правятся данными
- Есть доступная автоматическая награда (тесты), а pass@1/solve rate застыл
- Требуется более точный баланс безопасности (избыточные/недостаточные отказы)