

# Работа с текстами

Зачем мы работаем с данными: примеры применения;  
Предобработка, очистка данных.



# какие причины это делать?

- для дообучения моделей
- для аналитики
- для поиска
- ещё что-то?



# какие причины это делать?

- для дообучения моделей

Золотое правило: что на входе, то и на выходе

# какие причины это делать?


- для дообучения моделей
- для аналитики
  - приводим дубликаты “Moscow”, “Москва” и “москва” к одной сущности
  - унифицируем термины
  - выделяем смыслы, удаляя лишние слова

# какие причины это делать?

- для дообучения моделей
- для аналитики
- **для поиска**
  - ???




# извлечение информации



Моделирование топики

Ключевые слова и фразы, фактическая информация

Кластеризация




# МОДЕЛИРОВАНИЕ ТОПИКОВ

**Моделирование топиков** — неконтролируемый метод анализа текстов, цель которого:

- автоматически находить скрытые темы (**topics**) в коллекции документов;
- представлять каждый документ как смесь тем, а каждую тему — как набор ключевых слов.

Например, в отзывах:

- «качество товара» (слова: качество, материал, брак, надежность),
- «доставка» (слова: доставка, курьер, время, опоздание),



# когда полезно?

- **Аналитика больших текстовых корпусов:** форумы, соцсети, отзывы.
- **Автоматическая категоризация документов:** отчёты, статьи, тикеты в техподдержку.
- **Мониторинг трендов:** выявление новых тем, которые начали часто обсуждаться.
- **Подготовка данных для ML/LLM:** темы можно использовать как дополнительные признаки.





# извлечение фактов

## выделяем важные сущности


сущности: компании, имена, персоналии, etc

события: кто, что, где сделал и когда

отношения: связи между сущностями




# ИЗМЕНЕНИЕ ТЕКСТОВ



Перефразирование

Работа с пунктуацией, регистрами и сокращениями

Обогащение информации




# стандартизация

## зачем?

- аугментация данных
- приведение данных к определенному стандарту
- обогащение данных расшифровками

## например, в **запросах пользователей**:

- “памагити аформить отпуск” → “помогите оформить отпуск”
- “что такое БиР?” → “что такое БиР (отпуск по беременности и родам)”





# стандартизация

например, в **запросах пользователей**:

- “памагити аформить отпуск” → “помогите оформить отпуск”
- “что такое БиР?” → “что такое БиР (отпуск по беременности и родам)”




# стандартизация

например, в **запросах пользователей**:

- “памагити аформить отпуск” → “помогите оформить отпуск”
- “что такое БиР?” → “что такое БиР (отпуск по беременности и родам)”

например, в **текстах базы данных**:

- замена и вычитка HTML-тегов, приведение к более чистой форме без потери структуры



# удаление информации

- персональные данные
- повторения
- нерелевантной информации





# удаление информации

в наших флагманских магазинах  
“пятёрочка” теперь продают слонов и  
крокодилов

для уточнения информации звоните

светлана +79234562450



# удаление информации

в наших флагманских магазинах  
[redacted]” теперь продают слонов и  
крокодилов

для уточнения информации звоните

[redacted] [redacted]



# а что ещё?

Отнологии

Графы знаний

Разделение текста на чанки

