



Векторы

Векторные базы данных, эмбеддеры, MTEB



Что такое вектор (эмбеддинг)


Эмбеддинг (embedding) — это векторное представление объекта (текста, изображения, звука и т. д.) в многомерном числовом пространстве. Получается с помощью специальных моделей эмбеддеров



В чем отличие?



Энкодер

Эмбеддер




Энкодер


Каждому токenu -- отдельный вектор




Эмбеддер



Для всей входной последовательности
- один вектор



Где используется?




Кластеризация (Моделирование топики)

Классификация

Поиск информации (ретрив (retrieval))


Реранжирование (reranking)



Поиск информации (retrieve)

например, база знаний курса:



- Коллекция записей, текстов, презентаций (чанков) в БД
- Надо найти информацию в какой лекции находилось
- По запросу “эмбеддер” будут находиться наиболее подходящие запросы




Реранжирование

Получили список документов, но как **найти наиболее оптимальный?**

- Получили список документов (чанков)
- Сравниваем уже сами тексты друг с другом



векторные базы данных



Алгоритмы поиска

Точный поиск


- Линейная сложность поиска (чем больше документов, тем дольше ищется)
- Скорость зависит от размерности эмбединга
- Требуется много ресурсов
- Точность 100%

Примерный поиск (approximate ANN)


- Очень быстрый поиск
- Скорость почти не зависит от размерности эмбединга
- Требуется мало ресурсов
- Точность достигает 99%

HSNW (Hierarchical Navigable Small World)

- Графовый метод для поиска ближайших соседей.
- Строит многоуровневый граф: верхние уровни содержат редкие «дальние» связи, нижние — плотные локальные связи.
- Поиск идёт сверху вниз: сначала быстрый переход в нужный регион через верхние уровни, потом уточнение на нижнем.
- Достигает высокой точности и сублинейного времени поиска



векторные базы данных



FAISS (Facebook AI Similarity Search)

- In-memory DB
- Нет поддержки метаданных
- CPU/GPU варианты для хранения
- Среднее качество документации
- Поддерживает multi-vector
- Open-source

Qdrant

- In-memory DB и persistent
- Широкая поддержка метаданных, в том числе для поиска
- Хорошая документация
- Поддерживает multi-vector
- HTTP API
- Есть UI для управления
- Open-source
- Для изменения размеров надо создать новую коллекцию




PGVector

- Расширение для Postgres
- Для изменения размера эмбединга
нужная новая таблица/колонка
- Все плюсы и минусы PG для поиска
- Есть интеграция с SQLAlchemy и
другими ORM
- Нет поддержки multivector



Энкодер подробнее

- Модель
- Пулинг (получение вектора)
- Меры близости




Пулинги

- mean pooling
- cls pooling (first token)
- lasttoken pooling



CLS (first token) pooling

Векторное представление из
CLS-токена



Mean pooling

в наших флагманских магазинах
[redacted] теперь продают слонов и
крокодилов

для уточнения информации звоните

[redacted] + [redacted]



Lasttoken pooling


в наших флагманских магазинах
[redacted] теперь продают слонов и
крокодилов

для уточнения информации звоните

[redacted] + [redacted]



Как узнать




The screenshot shows a code editor interface with a dark theme. At the top, there's a breadcrumb navigation: "main" with a dropdown arrow, followed by "Qwen3-Embedding-0.6B / 1_Pooling / config.json". Below this, the username "littlebird13" and a commit message "Automatically add EOS via Tokenizer, integrate Sente" are visible. A toolbar contains icons for "raw", "Copy download link", "history", "blame", "contribute", "delete", and a search icon. The main area displays a JSON configuration file with the following content:

```
1  {
2    "word_embedding_dimension": 1024,
3    "pooling_mode_cls_token": false,
4    "pooling_mode_mean_tokens": false,
5    "pooling_mode_max_tokens": false,
6    "pooling_mode_mean_sqrt_len_tokens": false,
7    "pooling_mode_weightedmean_tokens": false,
8    "pooling_mode_lasttoken": true,
9    "include_prompt": true
10 }
```


Max Sim (colbert)

Для каждого токена запроса получаются



Меры близости

- Косинусная
- Евклидовая
- Манхэттенна
- Скалярное произведение (dot product)

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

cosine similarity

$$d(x, y) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2}$$

dot product

Как подбирать модель

English

Image

Domain-Specific

Language-specific

European

Indic

Scandinavian

Chinese

German

French

Japanese

Korean

Polish

Russian

Farsi

Vietnamese

Other

Miscellaneous

MTEB(rus, v1)

A Russian version of the Massive Text Embedding Benchmark with a number of novel Russian tasks in all task categories of the original MTEB.

- Number of languages: 1
- Number of tasks: 23
- Number of task types: 7
- Number of domains: 9

[Click for More Info](#)

Summary Performance per Model Size Performance per Task Type Performance per task Task information

Filter...

Rank (Box)	Model	Zero-shot	Memory U	Number of P	Embedding D	Max Tokens	Mean (T	Mean (TaskT	Classification	Clustering	Multilabel Class	Pair Classificat	Reranking
1	Giga-Embeddings-instruct	NA	12865	38	2048	4096	74.12	73.10	76.66	67.48	57.07	79.57	74.02
2	FRIDA	30%	3141	823M	1536	512	71.06	68.98	73.71	67.49	52.23	66.45	71.50
3	BERTA	30%	489	128M	768	512	69.34	67.86	71.22	64.78	56.46	65.74	69.72
4	Ling-Embed-Mistral	91%	13563	7B	4096	32768	67.46	64.62	71.16	62.92	42.71	60.00	69.57
4	GritLM-7B	91%	13813	7B	4096	32768	67.67	65.08	69.92	64.30	41.96	58.93	69.99
6	e5-mistral-7b-instruct	91%	13563	7B	4096	32768	67.16	64.99	69.07	64.24	42.93	60.81	69.96
7	multilingual-e5-large-instruct	91%	1068	560M	1024	514	65.00	63.36	66.28	63.13	41.15	63.89	64.35
8	gte-Qwen2-7B-instruct	NA	29040	7B	3584	32768			72.97	66.37	44.27	67.61	64.54
9	SFR-Embedding-Mistral	86%	13563	7B	4096	32768			69.81	64.92	42.95	60.65	70.46
10	jina-embeddings-v3	100%	1092	572M	1024	8194	63.45	60.93	65.24	60.90	39.24	59.22	53.86
11	SFR-Embedding-2_R	86%	13563	7B	4096	32768			70.20	64.87	42.60	58.49	68.21

Download Table