







РАГ-СИСТЕМЫ НАЧАЛО




RAG: просто



RAG: посложнее





на что можем влиять?




на что можем влиять?


теперь по пунктам:


 **предобработка запроса**

 метод поиска

 эмбеддер

 реранкер

 **постпроцессинг**

 **+ выбор модели для генерации**

– разберём сегодня

– разбирали в теме 3

– разбирали в теме 2

– разбирали в теме 4

– разберём сегодня

– разберём сегодня

QUERY EXPANSION




HyDE

HYPOTHETICAL DOCUMENT EMBEDDINGS


идея:

- ✓ хотим потенциальным ответом уточнить наш запрос и расширить область поиска
- ✓ полезно, если хотим “раздвинуть” два очень похожих вопроса


Обычный RAG



HyDE RAG



SelfQuery




ОСНОВНАЯ ИДЕЯ:

при помощи промптов вычленяем метаданные из запроса, сравниваем их с имеющимися в коллекции


FLARE

FORWARD-LOOKING ACTIVE RETRIEVAL



идея:

- хотим повторять поиск по документам каждый раз, когда модель теряет уверенность
- теряет уверенность = генерирует токены низкой вероятности



ПОИСК

эмбединги

что мы использовали?


- labse
- intfloat/multilingual-e5-large
- clips/mfaq

зачем пробовать разные?

качество эмбедингов
непосредственно влияет на
качество поиска похожих
документов: чем лучше
эмбединги работают с
русским языком, тем лучше
нужные документы
отранжированы под запрос

retrieve: chunking

Text



пробуем разные размеры чанков, исходя из логики



данных



желательно, чтобы чанки отличались семантически

помним про ограничение длины последовательности у би-энкодеров

Chunk

retrieve: ensemble

1. FAISS (baseline)

2. SVM

3. kNN

используют наши
эмбединги


4. BM25

5. TFIDF

используют свои
векторные
представления



retrieve: symmetric search




- ✓ индексируем чанки вопросами и сравниваем запрос пользователя с индексом
- ✓ вопросы генерируем или собираем вручную
- ✓ со временем накапливаем статистику с реальными запросами и дополняем индекс

ReRank


идея:

- ✓ Проиндексировать корпус чем-то легковесным для первичного отбора
- ✓ Вычислить их косинусное расстояние между парами запрос-ответ с помощью би-энкодера
- ✓ Взять топ K кандидатов и переранжировать их через кросс-энкодер





GENERATION



LLM prompting

пробуем:

- ✓ n-shot prompting
- ✓ cot (chain-of-thought)
- ✓ prompt chaining

ПОМНИМ:

- ✓ special tokens (bos, eos, etc.)
- ✓ prompt separation
- ✓ recency bias


LLM generation parameters


- ✓ temperature
- ✓ top k
- ✓ top p
- ✓ repetition penalty
- ✓ presence penalty (could be negative)



logitsprocessor


Идея: зануляем вероятности для ненужных нам токенов





ЧТО В ИТОГЕ?

roadmap



**И ЧТО, ВСЁ?
ТАК ПРОСТО?**

He совсем...



ГАЛЛЮЦИИ

Откуда?

ИЗ-ЗА НЕДОСТАТОЧНОСТИ КОНТЕКСТА

как проверить, достаточен ли контекст?

- ☑ установить порог “похожести” – значения косинусной близости !!
- ☑ воспользоваться llm -судьёй и решать, достаточен ли контекст?
- ☑ опираться на логики при генерации (как в hyde)

А ещё?


ЗАЩИТА НА ЭТАПЕ ГЕНЕРАЦИИ

до/после генерации

- ✓ генерировать в два этапа – т.н. prompt chaining – сначала просить Llm отобрать релевантные цитаты, затем генерировать на их основе
- ✓ в явном виде в промпте говорить “я не знаю”, если контекста недостаточно



КАК МЕРИТЬ?



метрики

- ✓ метрики расстояния между текстами
- ✓ метрики ранжирования
- ✓ llm-based метрики

метрики расстояния

- ✓ расстояние Хэмминга
- ✓ расстояние Левенштейна
- ✓ косинусное расстояние

$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

В чём минусы?

не очень хорошо
реагирует на

- грамматику
- галлюцинации и повторения

нужен эталон

метрики ранжирования

 map@k

 p@k

 ndcg@k

в чём минусы?

показывают только работу
самого ретривера, а не
всей rag системы в целом


нужен эталон

Ilm-based метрики

- ✓ groundedness – оценивает, насколько ответ модели обоснован с точки зрения контекста
- ✓ context relevance – оценивает, насколько контекст, добытый ретривером, соответствует вопросу пользователя

В чём минусы?

это все нестабильно, зависит от промптов, модели, погоды в казани и вообще субъективно и требует валидации ручками



КАК БЫТЬ?

перед началом работы

посмотрим на данные

- вопросы пользователей
- документы
- правильные ответы (aka “золотой набор”)

какие вопросы задать?

- как сильно отличаются вопросы и ответы?
- что замеряем? какая необходима точность?
- как часто делаем разметку? кто её делает?

**слайд на случай,
если я что-то забыла**

**СПАСИБО ЗА
ВНИМАНИЕ**

@XUFANA